

Кейс по аналитике

Улучшение автоматизации чат-бота в банковской поддержке

Ойслендер Ксения

#Product_Analytics #ML #Banking

[1] Бизнес-контекст

Банк использует чат-бот для автоматизации клиентской поддержки. Текущий уровень автоматизации составляет 30%. **Цель бизнеса** — увеличить показатель до 60% в течение 2 лет без ухудшения качества обслуживания клиентов.

Проблема: значительная часть диалогов передаётся операторам из-за ограничений логики сценариев, ошибок классификации интенгов и отсутствия обработки контекста диалога.

Таблица – Категории отказов чат-бота

Категория	Пояснение	Доля
У клиента бот отключен (например, ВИП, гость, должник)	Бот не участвует в диалоге по политике банка; эти клиенты сразу попадают к оператору.	9,6%
Бот не смог продолжить решение проблемы клиента, не хватает ветки	Бот понял вопрос, но не может довести сценарий до конца из-за отсутствия логики в сценарии.	6,7%
Не новый вопрос, продолжение предыдущего диалога	Бот теряет контекст или не связывает новое сообщение с прошлым.	5,4%
Бот интенг понял, но ответа в интенге нет	Бот знает, чего хочет клиент, но нет целого сценария.	3,3%

Бот не знает такого намерения	Бот не знает такого интента.	3,1%
Клиент зовет оператора	Пользователь напрямую просит «оператора», бот сразу на него переводит.	3,0%
Бот перевел из-за технической ошибки	Проблемы в инфраструктуре, API или сетевых соединениях.	2,6%
Клиент спрашивает в тему ответа	Бот отвечает, но клиент уточняет детали, диалог продолжается без эскалации.	2,3%
Интент есть, но не поняли формулировку	Классификатор не смог найти нужный интент.	1,7%
Клиент повторяет свой вопрос после ответа бота	Клиент повторяет свой вопрос, бот понимает, что скорее всего ответил что-то не то и переводит на оператора.	1,4%
Бот не смог понять ответ клиента на вопрос (слоты)	Бот не смог вытащить нужные данные из сообщения (например, дату, сумму) и заполнить слот).	1,3%
Клиент зовет оператора после ответа бота	Бот вроде ответил, но клиент видимо не удовлетворён качеством и зовет оператора.	1,1%
Клиент выразился слишком общо	Сообщение без контекста, бот не может понять, что конкретно от него надо.	1,0%
Бот понял не тот интент, ошибка классификации	Бот понял вопрос неверно и пошёл по другой ветке.	0,9%
Клиент отправил только картинку или файл	Бот не умеет работать с файлами.	0,8%
Клиент зовет оператора в середине	Бот не справился и отдал клиента слишком рано.	0,8%
Клиент выражает намерение в нескольких сообщениях (пулемётчик)	Клиент быстро отправляет несколько сообщений подряд; бот не успевает связать их между собой.	0,4%
Клиент отвечает картинкой на вопрос внутри сценария	Бот не умеет обрабатывать визуальные ответы внутри сценария.	0,4%
Клиент хочет закончить диалог	Пользователь просто завершает разговор.	0,4%

Бот дал слишком общий ответ: неперсонифицированный, селф-сервис	Бот даёт слишком общий совет без конкретики.	0,3%
Другое в категории "Бот не понял намерение"	Редкие или аномальные ошибки классификации.	0,3%
Клиент в одном сообщении задал несколько разных вопросов	Бот не может разделить их и отправляет на оператора.	0,2%
Другое в категории "Бот понял намерение верно, но не решил проблему самостоятельно"	Сценарий не покрывает шаги до результата.	0,2%
Бот дал неверный ответ	Бот ошибся логически или фактически.	0,1%
Клиент не выбрал нужную подсказку из предложенных в вопросе	Отказ от сценарного пути, бот не может продолжить.	0,0%
Всего:		100%

[2] Почему автоматизация чатов – неидеальная метрика?

Метрика доли автоматизации чатов (**automation rate**) измеряет количественный результат — какая часть диалогов была завершена без участия оператора — но не отражает реальное качество обслуживания клиентов и эффективность решения их проблем.



Проблема #1

Метрику **легко “накрутить”**. Бот может «автоматизировать» диалог, дав неверный или слишком общий ответ. Клиент уходит неудовлетворённым, но метрика растёт.



Проблема #2

Часть неавтоматизированных диалогов — норма: например, **9.6% отказов — это клиенты с отключённым ботом (ВИП, должники)**. Перевод таких клиентов на оператора — политика банка, а не провал бота. Включать их в «неавтоматизацию» некорректно.



Проблема #3

Автоматизированный диалог не значит решённая проблема.

Клиент может получить ответ, остаться недовольным и обратиться повторно. Тем не менее, это не отразится на метрике автоматизации.

[3] Метрики качества, которые реально важно отслеживать

Метрика	Описание	Плюсы	Минусы
FCR (First Contact Resolution)	Доля проблем, решённых без участия оператора с первого обращения	+ хорошо отражает реальную эффективность решения проблемы + Помогает выявлять проблемные сценарии	– сложно корректно измерить (например, клиент ушёл из чата, но вопрос остался нерешённым) – требует отслеживания повторных обращений (в т. ч. не через чат-бот)
CSAT (Customer Satisfaction)	Оценка клиентами качества ответов бота (короткий опрос после диалога)	+ прямой голос клиента + выявляет скрытые проблемы качества	– субъективность оценки – не все клиенты отвечают
Escalation Rate (по причинам)	Доля диалогов, переведённых на оператора — с разбивкой по категориям причин	+ легко измерить + показывает «узкие места» бота + отражает нагрузку на операторов	– не всегда означает проблему (некоторые переводы нормативны)

Intent Accuracy	Точность распознавания намерения клиента (precision/recall по интентам)	+ выявляет ML-проблемы + позволяет сравнивать модели оффлайн	- не отражает, решена ли проблема клиента - оффлайн-метрика рассчитывается на тестовой выборке, но фактическое качество распознавания может быть ниже, чем показывает метрика (пользователи допускают опечатки, пишут разговорным языком)
------------------------	---	---	--

[4] Топ-3 причины неавтоматизации

Выбор топ-3 самых важных причин (приоритетных задач) **обусловлен тремя критериями:** размер потери (% отказов), управляемость (насколько команда может это исправить) и техническая сложность решения.

#1	Не хватает ветки решения/нет целого сценария (6,7% + 3,3% = 10% отказов)
	Почему важно: бот понял вопрос клиента правильно, но сценарий для ответа не написан. Это самая управляемая из крупных причин.
	Решение: проанализировать логи диалогов и определить наиболее частые шаги, на которых происходит перевод на оператора, затем расширить существующие сценарии, добавив недостающие шаги.

Метрика успеха: Снижение доли «не хватает ветки/нет целого сценария» при неизменном CSAT; рост FCR.

#2

Потеря контекста/продолжение предыдущего диалога (5,4% отказов)

Почему важно: бот не умеет связывать новое сообщение с предыдущим диалогом, из-за чего каждый запрос воспринимается как новый, что напрямую влияет на пользовательский опыт. Это блокирует целый ряд сценариев, особенно многошаговых.

Решение: реализовать механизм отслеживания состояния диалога (conversation state tracking), при котором система сохраняет смысл последних сообщений клиента и передаёт его как контекст в классификатор интенгов (ML-подход). Быстрый старт без ML: правило «если диалог начат менее, чем через 1 час — предложить кнопку "продолжить предыдущий вопрос"».

Метрика успеха: снижение доли отказов по категории "продолжение предыдущего диалога"; рост FCR для многошаговых обращений.

#3

Неизвестный интент/не понял формулировку (3,1% + 1,7% = 4,8% отказов)

Почему важно: проблема напрямую связана с качеством NLP, влияет на удовлетворенность клиентов, хорошо решается с помощью машинного обучения.

Решение: переобучить классификатор интенгов на sentence embeddings, дообучить на реальных диалогах с аугментацией перефразировок и добавить fallback-интент с уточняющим вопросом вместо немедленного перевода на оператора.

Метрика успеха: рост intent precision/recall на валидации, снижение "не знает интент/не понял формулировку".

[5] Как проверять гипотезы (итерации и тесты)



Проверка гипотез основана на принципе **“от дешёвого к дорогому”**.



Никогда **не тестировать несколько изменений одновременно в одной группе** — иначе невозможно понять, что именно дало результат.

☐ **Оффлайн-анализ (нулевой риск)**

Задачи:

- Выгрузить диалоги с переводом на оператора за последние 3 месяца
- Вручную разметить выборку (300–500 диалогов) по реальной причине перевода
- Посчитать оффлайн-метрики: precision/recall классификатора
- Оценить потенциал: если написать топ-5 непокрытых сценариев — на сколько % откажет меньше?

☐ **A/B тест на малом трафике (5-10%)**

Запуск изменения на случайной выборке пользователей:

- Контрольная группа — старая версия бота
- Тестовая группа — версия с изменением (новые сценарии / новый классификатор)
- Контроль онлайн-метрик
- Минимум 2 недели
- Критерий остановки — если CSAT падает более, чем на 5%

☐ **Постепенное расширение**

После успешного A/B теста — поэтапное расширение аудитории: 25% — 50% — 100%.

Мониторинг ключевых метрик в реальном времени на каждом шаге.

[6] Проблема “Клиент сразу зовёт оператора”

3% диалогов – клиенты, которые даже не дают боту шанс. Чаще всего это **проблема доверия**, а не технических ограничений.

Необходимые исследования:

- ☐ **Интервью/опрос** клиентов, которые сразу зовут оператора (“Что заставляет вас не доверять боту?”, “Какие типы запросов вызывают недоверие?”)
- ☐ **Когортный анализ** клиентов, например, по возрасту/продукту/истории (у каких клиентов выше вероятность сразу звать оператора)
- ☐ **Анализ предыдущего опыта клиента** – проверить гипотезу, коррелирует ли “зовёт оператора” с наличием негативного предыдущего диалога.

[7] Как увеличить доверие к боту?

Стратегия может включать в себя следующие продуктовые изменения:

- Бот должен честно говорить “я не знаю” вместо неверного ответа
- Показывать возможности бота на примерах (например, “Я виртуальный помощник банка. Могу помочь с переводами, балансом и блокировкой карты” или “Я обновился и теперь умею решать <...>”)
- Показывать текущий статус обработки запроса (например, “нашёл вашу карту, проверяю транзакции...”)
- Сбор обратной связи в 1 клик после каждого диалога (“Я помог?”). Данные использовать для обучения модели
- Повышение точности ответов

[8] Рекомендуемый план действий

Ниже представлен **roadmap** улучшений чат-бота (сроком примерно **на 8 месяцев**).

Этап	Действие	Метрика успеха	Длительность
#1	Оффлайн-анализ (разметка диалогов, подсчет оффлайн-метрик, кластеризация непокрытых тем, определение топ-10 непокрытых обращений)	Intent accuracy	2-3 недели
#2	Написать сценарии для топ-10 непокрытых интенгов, затем – A/B тест на 10% трафика	Escalation rate, CSAT	4-6 недель
#3	Добавить боту “ память/сохранение контекста ” – conversation state tracking	FCR, снижение доли отказов по категории	6-8 недель
#4	Переобучить классификатор интенгов на sentence embeddings + аугментация перефразировками, добавить fallback-интент с уточняющим вопросом вместо немедленного перевода на оператора	Intent precision/recall, снижение “не знает интент/ не понял формулировку”	6-8 недель
#5	Исследования доверия к боту + эксперименты с персонализацией для “недоверяющих” сегментов	Escalation rate (по когорте), CSAT	8-10 недель

Ожидаемый результат: рост уровня автоматизации сначала до ~40-50% на этапах 1-3, а затем до целевых 60%.